

基于小波神经网络方法的降水量预测研究

侯泽宇, 卢文喜, 陈社明

(吉林大学环境与资源学院, 吉林 长春 130026)

摘要:小波神经网络作为国际上新兴的一种数学建模分析方法,充分继承了小波变换良好的时频局部化性质及神经网络的自学习功能和极强的非线性能力等优点。降水量预测模型中神经网络选择BP网络,隐含层激活函数选取Morlet小波,并利用MATLAB编写预测程序,运用吉林西部地区白城、长岭、前郭3个测站1957—2010年的降水资料对模型进行训练、检验,进而预测三站未来十年的降水量。研究结果表明,小波神经网络预测模型对降水量的变化趋势预测准确,结构简单,收敛速度快,具有较高的实际应用价值,但其对于降水量具体值的预测精度有待于进一步提高;未来十年,吉林西部地区将处于降水量变化周期的丰水阶段,各相关部门应根据实际情况做好相应的准备。

关键词:小波神经网络;降水量预测;吉林西部;MATLAB;丰水阶段

中图分类号:P338.9 **文献标识码:**A

Research on Precipitation Prediction Based on WNN

HOU Ze-yu, LU Wen-xi, CHEN She-ming

(College of Environment and Resources, Jilin University, Changchun 130026, China)

Abstract: As an emerging international mathematical modeling method, wavelet neural network (WNN) fully inherits many advantages, such as excellent time-frequency localization property of wavelet transform and self-learning function and strong ability nonlinear of neural network. In this paper, BP network is selected to be the neural network, the Morlet wavelet is chosen to be the hidden excitation function of precipitation prediction model, the MATLAB is used to write WNN prediction program, and then the model is trained and tested by using the precipitation information from 1957 to 2010 of the three hydrometric stations of Western Jilin province, including Baicheng, Changling, Qianguo, to forecast their precipitation of next decade. The research results show that the WNN prediction model is of high accuracy, simple structure, fast convergence rate and high practical value, while the prediction accuracy for specific value of precipitation needs further improvement. In addition, Western Jilin province will be in wet stage of the precipitation variation during next decade, so related departments should make preparations according to the actual situation.

Key words: wavelet neural network; precipitation prediction; western Jilin province; MATLAB; wet stage

降水是水文循环的重要环节,是陆地内各种水体直接或间接的补给源,因此,降水量和降水特征,对各种水体的水文特征和规律具有决定性的影响。降水量的短期剧烈变化,往往会造成旱涝灾害,从而严重地影响国民经济发展。研究准确地预测降水量,可提高应对灾害的能力,同时为工农业生产和工程建设提供可靠的气象方面的依据。但降水量变化属于典型的非

线性多维时间序列,隐含了大量的时序动态特征,又受当地地形、所处气候带、大气环流、洋流、太阳黑子以及人类活动等多种环境因子的影响,使得准确预测未来降水量的变化较为困难。

早期采用多因子的回归方程法预测,由于其线性方程比较简单而无法反映降水量的复杂变化规律;近些年较为常用的方

收稿日期:2012-10-08

基金项目:吉林省科技发展计划项目(20080456)。

作者简介:侯泽宇(1989-),男,硕士研究生,研究方向为水环境与水生态。E-mail: houzeyu890829@163.com。

通讯作者:卢文喜(1956-),男,教授,博士生导师,主要从事地下水数值模拟及水生态研究。E-mail: luwenxi@jlu.edu.cn。

法是人工神经网络,但其网络结构在应用过程中难以科学地确定,学习训练最优权值时,其BP算法存在陷于局部极小而使算法不收敛的固有缺陷,从而影响整个预测模型的可靠性和准确性;另外还有小波分析、随机分析法等,这些方法都没有考虑降水量变化的时间序列属性,从而无法反映其时序动态特征,致使预测精度普遍不高^[1]。结合小波变换与人工神经网络思想而形成的小波神经网络是近些年来国际上新兴的一种数学建模分析方法,既具有小波变换优越的时频特征提取能力,又具有神经网络的自学习、自适应以及对非线性输入、输出关系的任意逼近能力,已经开始有效地应用于模式识别、信号处理、故障诊断等众多领域。但是,小波神经网络方法在水文领域的发展还不成熟,应用实例较少,本文将引入降水量的预测,希望能为其以后在水文领域的应用提供一定的参考;同时,本次研究采用不同月份单独预测,最后汇总的方式,有效地减小了统一预测时由于各月降水量浮动剧烈而造成的较大预测误差,同时缩短了输入与输出序列的长度,有利于模型的运行,希望能为水文预测提供一种新的途径。

1 小波神经网络

1.1 小波神经网络结构

小波神经网络就是将常规单隐层神经网络隐含层节点的传统激活函数用小波函数来代替,相应的输入层到隐含层、隐含层到输出层权值及隐含层阈值分别由小波函数的尺度与平移参数所确定。小波神经网络具有比小波变换更多的自由度,从而使其具有更灵活有效的函数逼近能力。通过筛选恰当的各个参数,较少的级数项组成的小波神经网络就能够达到优良的逼近效果。因此,小波神经网络具有最佳的函数逼近能力,也就是最佳的模式识别能力。由于其建模算法不同于普通神经网络的BP算法,所以,可以有效地克服普通人工神经网络模型所固有的缺陷,用其所建预测模型可以取得更好的预测效果^[2]。小波神经网络结构见图1。




图1 小波神经网络结构

Fig. 1 Structure of WNN

1.2 小波神经网络工作原理

小波神经网络学习算法即训练的实现步骤。

(1)网络参数的初始化。将网络连接权值、学习率、动量因子以及小波的伸缩因子、平移因子赋予初始值,并置输入样本计数器。

(2)输入学习样本及相应的期望输出。

(3)计算隐含层及输出层的输出。利用输入层与隐含层之

间权值将输入样本加权求和,成为隐含层输入,再经过隐含层小波变换成为隐含层输出;利用隐含层与输出层之间权值将隐含层输出加权求和获得输出层输出。

(4)输入下一个样本及期望输出,即 $p = p + 1$ 。

(5)计算误差和梯度向量(目标误差函数 E)。

(6)判断算法是否结束。

当 $E < \epsilon$ 时,即目标误差函数 E 小于预先设定的某个精度值 ϵ ($\epsilon > 0$),停止网络学习,否则调整网络权值,将计数器重置为1,并转步骤(2)循环^[3]。

小波神经网络是在小波分析的基础上提出的一种多层前馈型网络,可以使网络从根本上避免局部最优并且加快了学习速度,所需训练次数大为减少。训练时,在权值和阈值的修正算法中加入动量项,利用前一步得到的修正值来平滑学习路径,避免陷入局部极小值,可进一步加快学习速度。给定 P ($p = 1, 2, \dots, P$) 组输入输出样本,学习率为 η ($\eta > 0$),动量因子为 λ ($0 < \lambda < 1$)。

目标误差函数:

$$E = \sum_{p=1}^P E^p = \frac{1}{2P} \sum_{p=1}^P \sum_{n=1}^N d_n^p - y_n^p \quad (1)$$

式中: d_n^p 为输出层第 n 个节点的目标输出; y_n^p 为网络输出层第 k 个节点的实际输出。

隐含层输出:

$$O_k^p = h\left(\frac{I_k^p - b_k}{a_k}\right), \quad I_k^p = \sum_{m=1}^M \omega_{km} x_m^p \quad (2)$$

式中: I_k^p 为隐含层第 k 个节点的输入; x_m^p 为输入层第 m 个节点的输入; O_k^p 为隐含层第 k 个节点的输出; a_k 为伸缩因子; b_k 为平移因子; ω_{km} 为连接输入层第 m 个节点与隐含层第 k 个节点的权值; $h(\cdot)$ 为小波函数(此处选用 Morlet 函数)。

输出层输出:

$$y_n^p = \sum_{k=1}^K \omega_{nk} O_k^p \quad (3)$$

式中: ω_{nk} 为连接隐含层第 k 个节点与输出层第 n 个节点的权值。

ω_{nk} 调整式:

$$\omega_{nk}^{new} = \omega_{nk}^{old} + \eta \sum_{p=1}^P \delta_{nk} + \lambda \Delta \omega_{nk}^{old} \quad (4)$$

$$\delta_{nk} = \frac{\partial E_n^p}{\partial \omega_{nk}} = (d_n^p - y_n^p) \cdot y_n^p \cdot (1 - y_n^p) \quad (5)$$

式中: ω_{nk}^{new} , ω_{nk}^{old} 分别表示调整后与调整前的 ω_{nk} ; $\Delta \omega_{nk}^{old}$ 为动量项。

ω_{km} 调整式:

$$\omega_{km}^{new} = \omega_{km}^{old} + \eta \sum_{p=1}^P \delta_{km} + \lambda \Delta \omega_{km}^{old} \quad (6)$$

$$\delta_{km} = \frac{\partial E_n^p}{\partial \omega_{km}} = \sum_{n=1}^N (\delta_{nk} \omega_{nk}) \cdot \frac{\partial O_k^p}{\partial I_k^p} \cdot x_m^p \quad (7)$$

式中: ω_{km}^{new} , ω_{km}^{old} 分别为调整后与调整前的 ω_{km} ; $\Delta \omega_{km}^{old}$ 为动量项。

伸缩因子调整式:

$$a_k^{new} = a_k^{old} + \eta \sum_{p=1}^P \delta_{ak} + \lambda \Delta a_k^{old} \quad (8)$$

$$\delta_{ak} = \frac{\partial E_n^p}{\partial a_k} = \sum_{n=1}^N (\delta_{nk} \omega_{nk}) \cdot \frac{\partial O_k^p}{\partial a_k} \quad (9)$$

式中： a_k^{new} 、 a_k^{old} 为调整后与调整前的 a_k ； Δa_k^{old} 为伸缩因子动量项。

平移因子调整式：

$$b_k^{new} = b_k^{old} + \eta \sum_{p=1}^P \delta_{b_k} + \lambda \Delta b_k^{old} \tag{10}$$

$$\delta_{b_k} = \frac{\partial E_n^p}{\partial b_k} = \sum_{n=1}^N (\delta_{nk} \omega_{nk}) \cdot \frac{\partial O_k^p}{\partial b_k} \tag{11}$$

式中： b_k^{new} 、 b_k^{old} 为调整后与调整前的 b_k ； Δb_k^{old} 为平移因子动量项^[4]。

利用计算机编程并运行，学习速度已经很快，动量项的效果并不明显，可以舍去，本文预测模型未引入。

2 实例应用

2.1 降水量预测模型的建立及训练

本文利用 MATLAB 编写程序建立小波神经网络预测模型，预测模型以 BP 网络作为基本框架，采用 3 层结构，隐含层激发函数选择 Morlet 函数^[5]，其表达式为：

$$h(\frac{x-b}{a}) = \cos(1.75 \frac{x-b}{a}) \exp[-0.5(\frac{x-b}{a})^2] \tag{12}$$

首先，按月整理降水资料，即把各年相同月份的降水量整理到一起；然后，以白城站为例，将白城站 1957—1986 年 1 月份的降水量作为输入，1987—1996 年 1 月份的降水量作为目标输出对预测模型进行训练。预测模型输入层包含 30 个节点，输出层包含 10 个节点；隐含层节点数的确定则较为困难，目前还没有固定、科学的确定方法。隐含层节点数量太少，网络从样本中获取信息的能力就差，不足以概括和体现训练集中的样本规律；隐含层节点数量过多，又可能把样本中非规律性的内容也学会记牢，从而出现所谓的“过拟合”问题，反而降低了网络的泛化能力。为尽可能避免训练时出现“过拟合”现象，保证足够高的网络性能，确定隐含层节点数的最基本原则是：在满足精度要求的前提下取尽可能紧凑的结构，即取尽可能少的隐含层节点。最初确定依据经验公式 $n = (M + N) / 2$ ， M 为输入层节点数， N 为输出层节点数，再通过网络训练过程中误差目标函数的收敛情况以及预测值与真实值的拟合情况不断对其进行调整，最终确定隐含层节点数为 26^[6-9]。

训练过程中目标误差函数的收敛情况如图 2 所示。




图 2 目标误差收敛曲线
Fig. 2 Convergence curve of Target error

最终，目标误差可以缩小至 3.8858×10^{-16} ，训练精度非常高，而且在迭代 50 次左右时就已经达到了收敛，收敛速度较普通神经网络有了极大的提升。

2.2 模型检验

由于预测模型每次的运行过程都是独立的，所以每次训练结束后都能得到一组全新的网络权值，使得预测结果存在差异。为了尽可能大地提高预测精度，在预测前需要对模型进行检验，具体检验过程为：利用 1971—2000 年 1 月份的降水量预测 2001—2010 年 1 月份的降水量，并与实际数据进行对比，拟合良好后保存模型，若差异较大，则重新运行，直到拟合情况在允许范围内为止。

检验程序与训练程序相衔接并同时运行，最终得到的拟合




图 3 白城站 2001—2010 年 1 月份降水量预测检验拟合曲线
Fig. 3 Precipitation forecast test fitting curve of Baicheng station, January, 2001—2010

曲线如图 3 所示。通过观察拟合曲线可以发现，预测降水量的变化趋势与实际值基本保持一致；但是，由于降水量的具体值有很大的随机性，部分降水量较小月份的预测相对误差较大，有时预测结果会出现负值，此时应根据实际情况，考虑多方面因素，进行适当的调整。所以，该模型的预测能力较为理想，预测结果能够提供较为可靠的参考，但在预测精度方面还有一定的不足之处，需要进一步的研究。

训练及检验程序均用于白城站 2011—2020 年 1 月份降水量的预测作为示例给出，其他月份或测站降水量的预测需要用相应的数据对模型进行训练、检验，文中不做赘述。

2.3 降水量预测及预测结果分析

预测时，将 1989—2010 年的降水数据输入经过训练、检验的预测模型，即可对白城、长岭和前郭站 2011—2020 年的逐月降水量进行预测。

将预测结果与原始资料汇总，可获得 1957—2020 年三站的降水量变化趋势图(图 4、图 5 和图 6)、2011—2020 年三站的年降水量以及 1957—2020 年三站不同时期的多年平均降水量(表 1 和表 2)。




图 4 白城站 1957—2020 年降水量变化趋势图
Fig. 4 Annual precipitation variation trend chart of Baicheng station during 1957—2020




图5 长岭站 1957—2020 年降水量变化趋势图

Fig. 5 Annual precipitation variation trend chart of Changling station during 1957—2020




图6 前郭站 1957—2020 年降水量变化趋势图

Fig. 4 Annual precipitation variation trend chart of Qianguo station during 1957—2020

表1 年降水量预测结果

Tab. 1 Forecast results of annual precipitation

年份	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020
白城	357.42	555.81	581.52	514.84	409.86	616.81	513.5	491.35	429.77	353.47
长岭	418.39	288.89	695.51	560.48	387.23	471.34	500.46	481.17	341.36	539.71
前郭	544.88	572.25	344.47	539.36	535.84	354.68	374.46	546.42	285.61	398.59

表2 1957—2020 年不同时期多年平均降水量

Tab. 2 Average annual precipitation in different periods during 1957—2020

年份	1957—2010	2011—2020	1957—2006	1971—2020
白城	390.00	482.44	394.98	394.86
长岭	441.00	468.45	446.03	435.83
前郭	423.94	449.66	424.67	424.35

通过分析预测数据和降水量总体变化趋势图(图4、图5及图6)可以发现,三站的降水量变化均具有周期性,且未来十年三站的降水量变化与周期相吻合。对比可以看出,未来十年三站的多年平均降水量均明显大于历史多年平均降水量,处于变化周期的丰水阶段;三站 1971—2020 年多年平均降水量均较 1957—2006 年多年平均降水量偏小,但差值十分微小,可知降水量依然保持原有水平,但有逐渐减小的趋势(具体见表2)。未来三站个别年份的降水量偏高或偏低,当地有关部门需要根据实际情况做好相应的防汛或抗旱准备(具体见表1)。

白城、长岭、前郭三站均处于吉林西部地区,所以在降水量变化方面应该具有相近的总体趋势。本次预测虽然依据原始数据对三站未来十年的降水量进行独立的预测,但预测结果显示,三站降水量的变化趋势十分相近,所以小波神经网络预测模型的预测结果具有较高的可信度^[10]。

3 结 论

通过建立小波神经网络预测模型,利用 1957—2010 年白城、长岭、前郭站的降水资料对其训练、检验,进而预测未来十年各站逐月的降水量,可以发现小波神经网络结构简单,收敛速度快,既继承了小波变换良好的时频局部化特性,能充分地分析降水量的变化规律,并获取其变化过程中的大体趋势与细节信息,又拥有神经网络的自学习功能和极强的非线性能力等优点,可以学习和泛化降水量的变化规律以应用于预测。

预测结果表明,小波神经网络预测模型对于降水量变化趋势的预测能力十分出色,但降水量的影响因素众多,具有很大的随机性,使得个别月份的降水量预测值存在较大的相对误差,有时甚至会出现预测值为负值的现象,所以该模型有待于进一步完善。但瑕不掩瑜,小波神经网络预测模型依然具有非常大的实际应用价值。未来十年,三站将处于降水量变化周期的丰水阶段,但也有个别年份的降水量偏低,相关部门应根据实际情况做好防汛或抗旱准备。

参考文献:

- [1] 常 青,赵晓莉. 时间序列模型在降水量预测中的应用研究[J]. 计算机仿真, 2011, 28(7): 204—206.
- [2] 牛东晓,邢 棉. 时间序列的小波神经网络预测模型的研究[J]. 系统工程理论与实践, 1999, 28(5): 89—92.
- [3] 侯媛彬,杜京义,汪 梅. 神经网络[M]. 西安: 西安电子科技大学出版社, 2007.
- [4] 张泉灵,王树青. 基于神经网络的非线性预测函数控制[J]. 浙江大学学报, 2001, 35(5): 497—501.
- [5] 邱继征. 小波分析原理[M]. 北京: 科学出版社, 2009.
- [6] 傅荟璇,赵 红. MATLAB 神经网络应用设计[M]. 北京: 机械工业出版社, 2010.
- [7] Batro A G. Neuron like adaptive element that can solve difficult learning control problems[J]. IEEE Transactions on SMC, 1983, 13(5): 834—846.
- [8] 侯媛彬. 提高神经网络收敛速度的一种赋初值算法研究[J]. 模式识别与人工智能, 2001, 14(4): 385—389.
- [9] 周开利,康耀红. 神经网络模型及其 MATLAB 仿真程序设计[M]. 北京: 清华大学出版社, 2005.
- [10] 卢文喜,陈社明,王晨子,等. 基于小波变换的大安地区年降水量变化特征[J]. 吉林大学学报(地球科学版), 2010, 20(1): 121—127.